9주차_10장(자연어처리와 컴퓨터비전 심층학습)

비전 트랜스포머

- **비전 트랜스포머 (ViT)**: 이미지 인식을 위한 딥러닝 모델
  - 이미지를 자연어 처리 방식처럼 분류해보려는 시도에 의해 탄생됨
  - 트랜드포머 모델에서 사용되는 셀프 어텐션을 적용
- ViT는 2차원 구조의 이미지 특성을 온전히 반영 X
  → 스윈 트랜스포머와 CvT 모델 탄생
- **스윈 트랜스포머 (Swin Transformer)**: 로컨 윈도를 활용해 각 계층의 어텐션이 되는 패치의 크기와 개수를 다양하게 구성해 이미지의 특성을 학습
  - 셀프 어텐션을 로컬 윈도 안에 대한 어텐션, 로컬 윈도 간의 어텐션으로 수행해 이미지 특징을 계층적으로 학습
  - 어텐션 함수에 상대적 위치 편향을 반영해 어텐션 값 자체에 위치적 정보를 포함시킴
- **CvT (Convolutional Vision Transformer)**: 기존 합성곱 연산을 ViT에 적용한 모델
  - 저수준 특징(ex. 눈,코,입)과 고수준 특징(ex.전체 얼굴)을 계층적으로 반영할 수 있음
  - 어텐션 연산 과정에서 키, 값을 축소해 계산 복잡도 감소

1. ViT

- 이전에는 합성곱 신경망에 트랜스포머 모델의 셀프 어텐션 모듈을 적용한 모델이 많았음
- ViT는 트랜스포머 구조 자체를 컴퓨터비전 분야에 적용한 첫 번째 연구

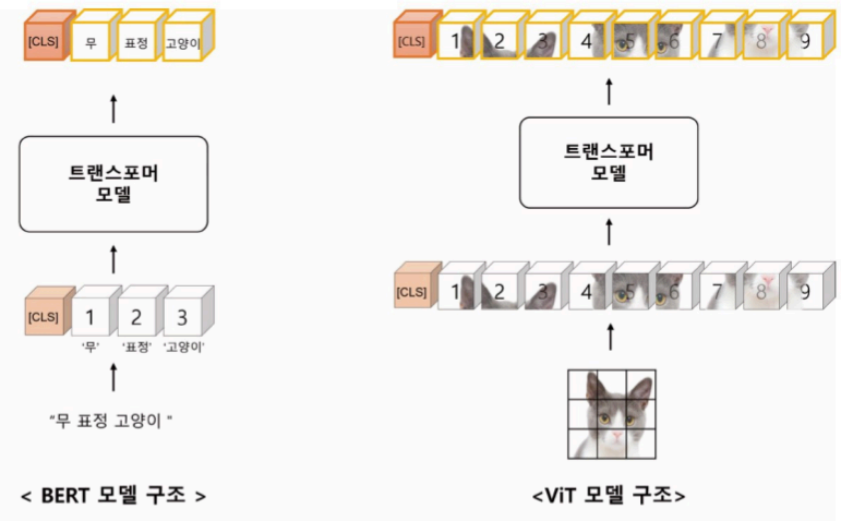

→ BERT는 토큰들이 순차적으로 입력, ViT는 이미지가 이미지 패치로 나뉘어 순차적으로 입력됨.

- 입력 이미지 패치는 왼쪽 → 오른쪽, 위 → 아래 순서로 나열됨

[합성곱 모델과 ViT 모델 비교]

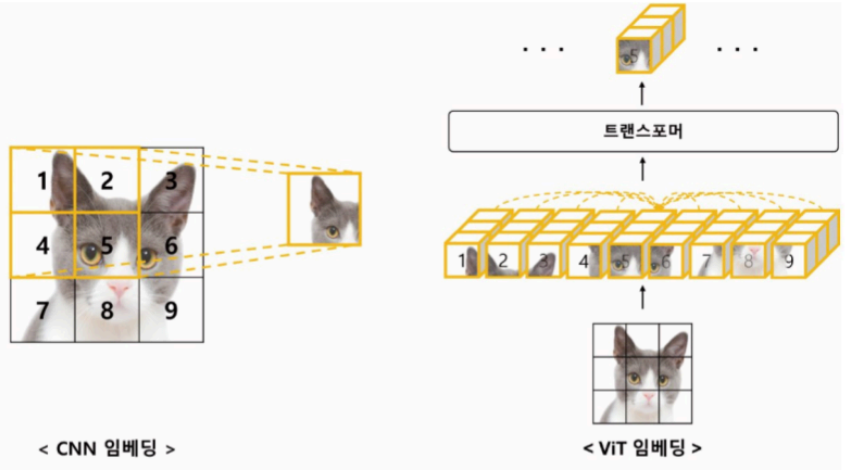

- 합성곱 신경망
  - 이미지 패치 중 일부만 선택하여 학습, 이를 통해 이미지 전체의 특징을 추출
  - 전체 이미지 정보를 표현하는 데 많은 계층 필요
  - 이미지의 공간적인 위치 정보 고려함
- ViT
  - 이미지를 작은 패치들로 나눠 셀프 어텐션 방법을 사용해 각 패치 간의 상관 관계를 학습

- 모든 이미지 패치가 학습에 관여, 높은 수준의 이미지 표현 제공
- 한 개의 레이어로 전체 이미지 정보 표현 가능
- 패치 단위로 이미지를 처리하기 때문에 더 작은 모델로도 높은 성능 보임
- 입력 이미지 크기가 고정, 전처리 필요
- 패치 간의 상대적인 위치 정보만 고려 → 이미지 변환에 취약

[ViT의 귀납적 편향]

- **귀납적 편향 (Inductive Bias):** 일반화 성능 향상을 위한 모델의 가정

딥러닝 모델	귀납적 편향
합성곱 신경망(CNN)	지역적 편향
순환 신경망(RNN)	순차적 편향
ViT	귀납적 편향이 거의 없음

- 해당 모델이 데이터에 적합한 가정을 하고 있음을 나타냄 → 더 적은 데이터로 높은 일반화 성능 보임
- 그러나 너무 강한 귀납적 편향은 다른 유형의 데이터나 관계를 표현하기 어려울수도

[ViT 모델]

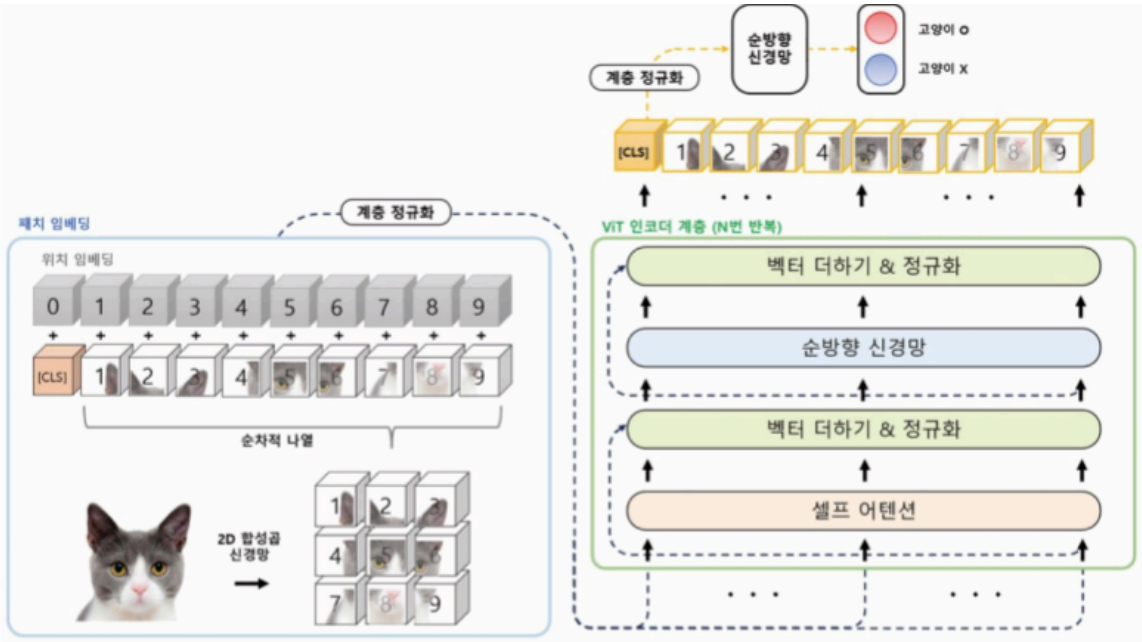

- 패치 임베딩 + 인코더 계층 → 이미지 특성 추출

- 이후 작업(ex. 분류, 회귀)에 맞는 출력값으로 변환해 사용
- **패치 임베딩**: 입력 이미지를 일정한 크기의 패치로 나눈 후 벡터 형태로 변환
  1. 정방형 크기로 이미지 조절
  2. 전체 이미지를 패치 크기로 분할해 시퀀셜 배열 만듦
     (합성곱 신경망의 계층 활용)

$$patch\ size = \frac{image\ size - kernel\ size}{stride} = \frac{9-3}{3} + 1 = 3$$

  3. 배열 가장 왼쪽에 분류 토큰 (CLS) 추가
     - 분류 토큰: 전체 이미지를 대표하는 벡터
  4. 위치 임베딩을 사용해 인접한 패치 간의 관계 학습
     - 위치 임베딩: 패치의 위치 정보를 임베딩 벡터로 변환하고 기존 이미지 패치 벡터들과 더함
  5. 계층 정규화 적용
- **인코더 계층**: 각 패치와의 관계 학습
  - 멀티 헤드 어텐션의 학습 과정과 동일
  - N개의 인코더 레이어를 반복적으로 적용 후 마지막 레이어에서 분류 토큰 추출
  - 분류 토큰 벡터를 완전 연결 계층에 연결

2. Swin Transformer

- 기존 트랜스포머 기반 모델의 문제점
  - 고정된 패치 크기로 인해 세밀한 예측을 필요로 하는 작업에 적합 X
  - 이미지 크기에 대한 2차 계산 복잡도 가짐 → 고해상도 이미지 처리 X

  ⇒ 스윈 트랜스포머: 계층적 특징 맵을 구성해 1차 계산 복잡도 가짐
- 시프트 윈도 방식 사용: 입력 이미지를 일정한 크기의 패치로 분할하고 이를 쌓아 윈도를 구성, 구성된 윈도 영역만 셀프 어텐션을 계산
  → 효율적 처리

[ViT와 스윈 트랜스포머 차이]

- ViT
  - 획일적인 패치 크기 + 위치에 대한 제약 → 다양한 이미지 크기에 적용 X
  - 패치 단위로 입력 받음 → 이미지의 공간 정보 완전히 보존 X
  - 이미지의 패치 수 증가하면 학습 데이터의 크기가 커지기 때문에 대규모 데이터세트에서 컴퓨팅 자원 많이 사용
- 스윈 트랜스포머
  - 로컬 윈도를 사용해 물체의 크기나 해상도를 계층적으로 학습
    - 로컬 윈도: 입력 이미지를 처리하기 위해 사용되는 고정 크기의 작은 위도
  - 시프트 윈도 기술로 입력 이미지를 패치로 분할하고, 특징 맵을 이동시켜 다음 계층에 사용 → 패치의 위치 유연

⇒ 더 높은 정확도, 더 적은 매개변수, 더 넓은 범위의 이미지 크기와 종횡비

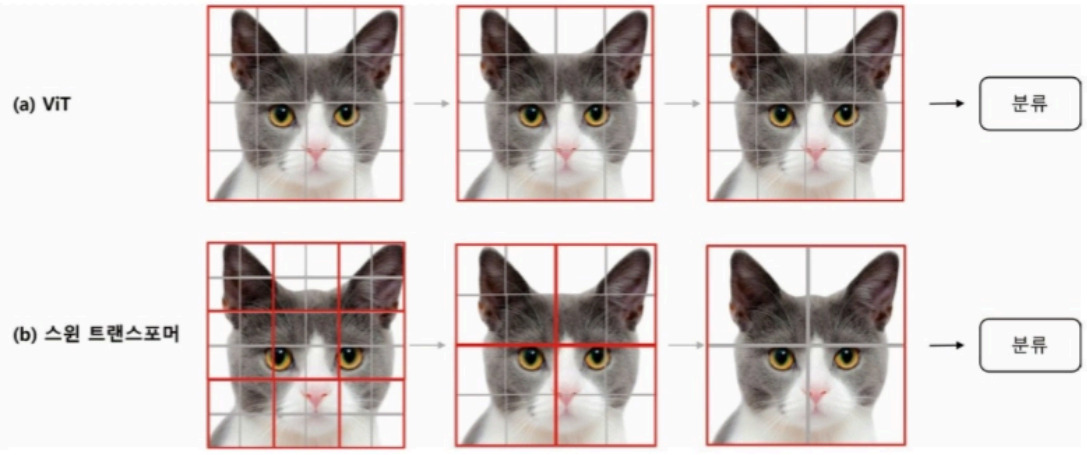

	ViT	스윈 트랜스포머
분류 헤드	[CLS] 토큰 사용	각 토큰의 평균값 사용
로컬 윈도 사용	X	O
상대적 위치 편향 사용	X	O
계층별 패치 크기	동일함	다양함

[스윈 트랜스포머 모델 구조]

1. 이미지를 일정한 크기의 패치로 분할
2. 각 패치에 대해 선형 임베딩 수행

3. 분할된 패치들을 기반으로 스윈 트랜스포머 블록 구성

   → 어텐션 계층, 계층 정규화, 다층 퍼셉트론 등 포함. 패치 간 상호작용 수행

4. 패치 병합 ⇒ 반복

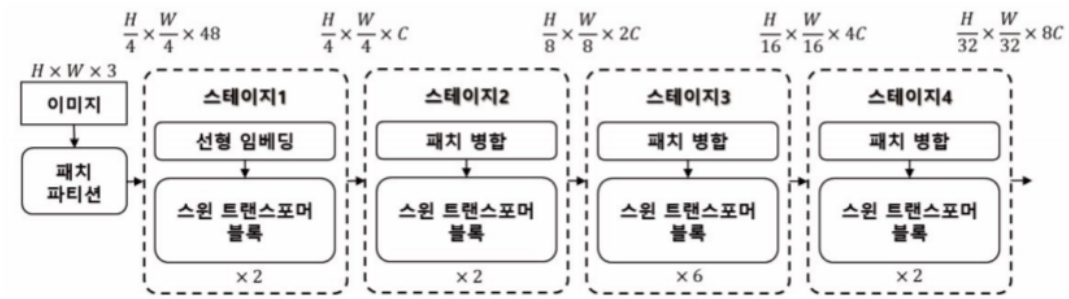

- 스윈 트랜스포머 블록: 계층 정규화, W-MSA, MLP, SW-MSA 등으로 구성

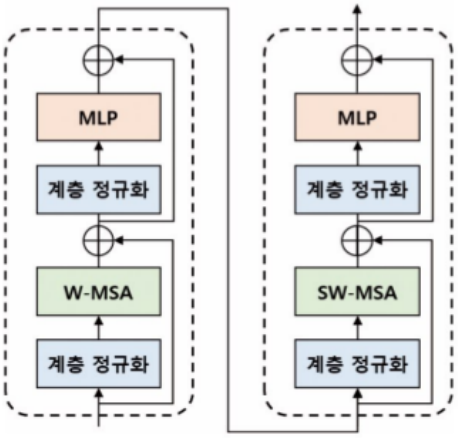

  - W-MSA: 로컬 윈도를 사용하는 멀티 헤드 셀프 어텐션
    - 입력 특징 맵을 중첩되지 않게 나눈 다음 각 윈도에서 독립적으로 셀프 어텐션 수행
    - 각 윈도 내 지역적인 특징 분석
    - 셀프 어텐션 비용을 2차 계산 복잡도에서 1차로 줄임
  - SW-MSA: 윈도 사이의 연결성을 구축해 윈도 간의 관계성 정보를 추출
    - 윈도를 가로/세로 방향으로 이동 후 인접한 윈도 간의 셀프 어텐션을 계산
    - 순환 시프트 + 어텐션 마스크를 사용해 연산을 효율적으로 수행
      - 순환 시프트: 윈도를 일정 거리(보통 절반)만큼 이동시키되, 밀려난 부분을 반대편으로 붙여 구조를 유지하며 이웃 영역과 연결함
      - 어텐션 마스크: 이동된 위치에서 연산을 수행하지 않게 함

- 로컬 윈도 안에 있는 패치 간의 상대적 거리를 임베딩하기 위해 상대적 위치 편향을 고려한다.

수식 10.2 상대적 위치 편향을 고려한 셀프 어텐션

$$Attention(Q,K,V) = SoftMax(QK^T / \sqrt{d} + B)V$$

3. CvT

- 합성곱 신경망 구조에서 활용하는 계층형 구조를 ViT에 적용한 모델
- 이미지의 지역 특징(합성곱 계층)과 전역 특징(셀프 어텐션 계층)을 모두 활용해 적은 수의 매개변수로 높은 성능 보임

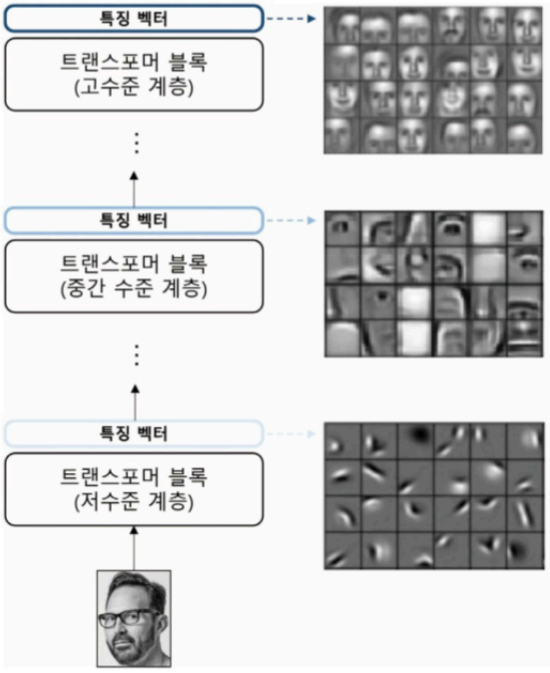

- 이미지를 처리하기 전에 합성곱 연산을 통해 특징 맵 추출

모델	위치 임베딩	패치 임베딩	어텐션 임베딩	계층형 구조
ViT	O	겹치지 않는 선형 임베딩	선형 임베딩	X
CvT	X	겹치는 합성곱 임베딩 (overlapping)	합성곱 임베딩	O

[합성곱 토큰 임베딩]

- 2D로 재구성된 토큰 맵에서 중첩 합성곱 연산을 수행하는 임베딩

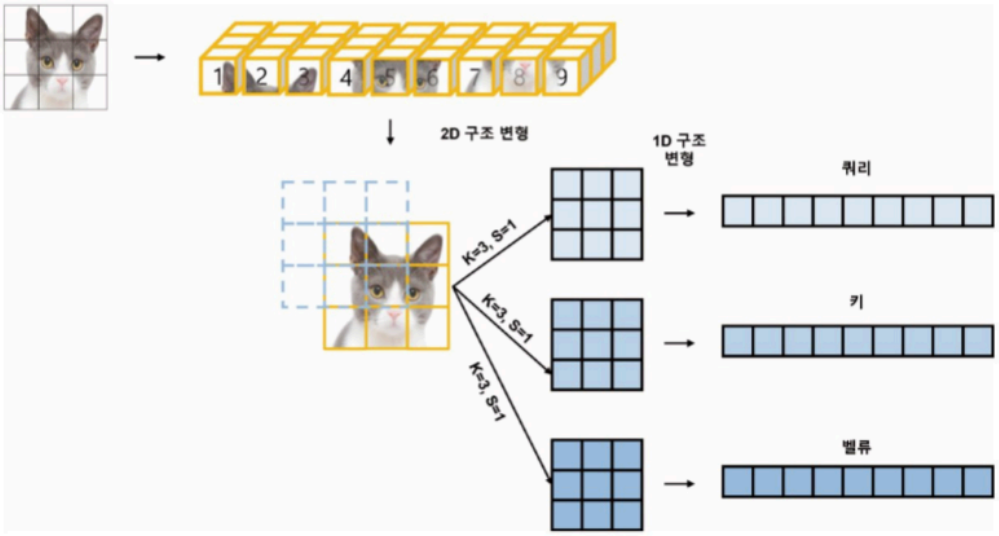

[어텐션에 대한 합성곱 임베딩]

- 2D로 재구성된 토큰 맵에서 분리 가능한 합성곱 연산을 적용해 성능 저하 및 계산 복잡도를 낮추는 연산

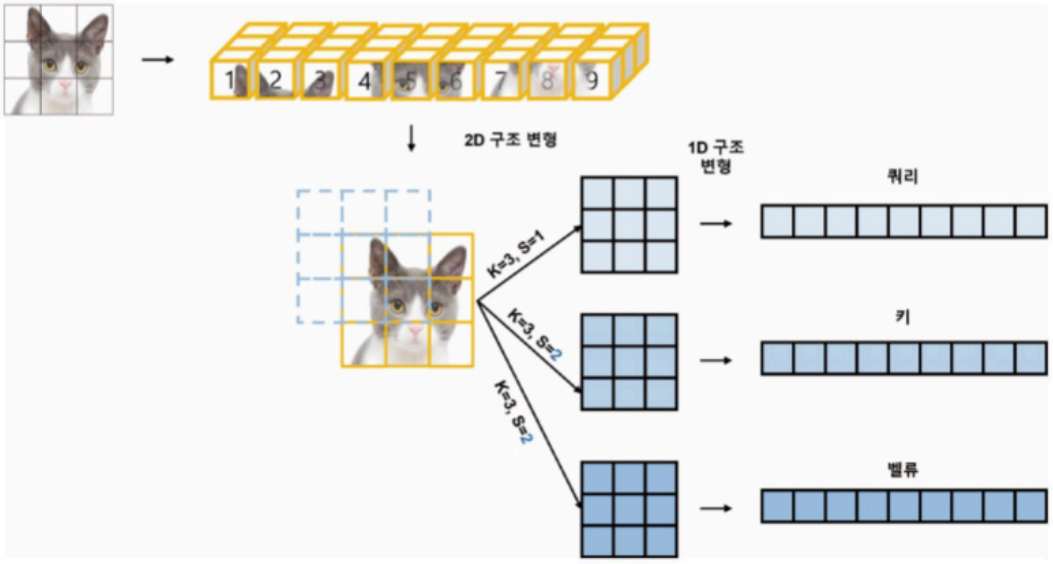

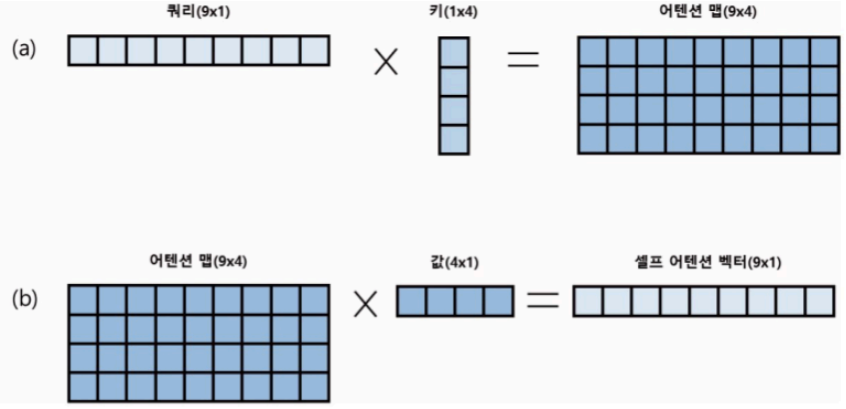

- 어텐션 맵: 쿼리 패치 임베딩과 키 패치 임베딩에 대한 중요도
- 계층이 깊어질수록 패치 간의 관계를 학습하는 길이를 축소시키는 대신 벡터의 차원을 증가시켜 모델의 매개변수 수를 감소시킴