

12주차_7장(~GPT)_자연어처리와 컴퓨터비전 심층학습

7. 트랜스포머

1. Transformer

- **트랜스포머**: 기계 번역, 챗봇, 음성 인식 등 다양한 자연어 처리 분야에서 많은 성과를 내는 딥러닝 모델 중 하나
- 기존 순환 신경망(RNN)과 달리 입력 시퀀스를 **병렬로 처리**하여 긴 시퀀스를 빠르고 효율적으로 처리 가능
- **셀프 어텐션(Self-Attention) 기반**: 순차 처리나 반복 연결에 의존하지 않고 입력 토큰 간의 관계를 직접 처리하고 이해함 (재귀나 합성곱 연산 없음)
- **학습 구조 및 방향성에 따른 분류**
 - **오토 인코딩(Auto-Encoding) 방식**: 랜덤하게 문장 일부를 빈칸 토큰으로 만들고 적절한 단어를 예측. 양방향 구조를 가지며 이를 **인코더**라고 함 (ex. BERT)
 - **자기 회귀(Auto-Regressive) 방식**: 이전 단어들이 주어졌을 때 다음 단어를 예측. 단방향 구조를 가지며 이를 **디코더**라고 함 (ex. GPT)
 - **구조별 대표 모델 요약**

모델	학습구조	학습방법	학습 방향성
BERT	인코더	오토 인코딩	양방향
GPT	디코더	자기 회귀	단방향
BART	인코더+디코더	오토 인코딩+자기 회귀	양방향+단방향
ELECTRA	인코더+판별기	오토 인코딩+대체 토큰 탐지	양방향
T5	인코더+디코더	오토 인코딩+자기 회귀+다양한 자연어 처리 작업을 학습	양방향

[입력 임베딩과 위치 인코딩]

- **단어 벡터화**: 입력 시퀀스의 각 단어는 임베딩 처리되어 벡터 형태로 변환됨. 원-핫 벡터 $([1, V])$ 는 임베딩 행렬 $([V, D])$ 에 의해 $[1, d]$ 크기의 벡터로 변환되며, N 개의 문장이 최

대 S개의 토큰 길이를 가질 때 [N, S, d] 크기의 임베딩 텐서로 변환되어 모든 계층에서 공유됨.

- **위치 인코딩(Positional Encoding) 도입 배경:** 순환 신경망과 달리 입력 시퀀스를 병렬 구조로 처리하므로 단어의 순서 정보를 제공하지 않음. 따라서 위치 정보를 임베딩 벡터에 추가해 단어의 순서 정보를 모델에 반영해야 함.
- **위치 인코딩 벡터 생성:** 각 토큰의 위치를 각도로 표현해 sin 함수와 cos 함수를 사용해 계산하며, 이를 임베딩 벡터와 더해 최종 입력 벡터를 생성함. 임베딩 차원 인덱스가 짝수면 sin 함수를, 홀수면 cos 함수 수식을 적용

$$PE(pos, 2i) = \sin(pos/10000^{2i/d_{model}})$$
$$PE(pos, 2i + 1) = \cos(pos/10000^{2i/d_{model}})$$

- **register_buffer 메서드 활용:** PyTorch 코드 구현 시 모델이 매개변수(Weights)를 갱신하지 않고 고정된 위치 인코딩 값을 유지하도록 설정하기 위해 사용됨.

[특수 토큰]

- **특수 토큰:** 단어 토큰 이외의 특별한 토큰을 활용하여 문장을 표현하며, 모델이 입력 시퀀스의 시작과 끝을 인식하게 하거나 특정 영역을 마스킹/무시할 수 있도록 함. 일반적으로 원-핫 인코딩으로 표현되어 어휘 사전에 등록됨.
- **주요 특수 토큰 종류 및 역할**
 - **<BOS>** (Beginning of Sentence): 입력 문장의 시작 부분에 추가되는 토큰.
 - **<EOS>** (End of Sentence): 입력 문장의 끝을 나타내는 토큰.
 - **<UNK>** (Unknown): 어휘 사전에 없는 단어 혹은 모델이 이전에 본 적 없는 모르는 단어를 처리할 때 사용됨.
 - **<PAD>** (Padding): 짧은 문장의 빈 공간을 채워 모든 문장의 길이를 일정한 크기로 맞추기 위해 사용됨.

[트랜스포머 인코더]

- **트랜스포머 인코더:** 입력 시퀀스를 받아 여러 개의 인코더 계층(블록)을 거치며 연산을 수행하고 특징 정보를 추출하여 디코더로 전달함. 층을 통과할수록 입력 시퀀스의 정보가 점차 추상화됨.
- **멀티 헤드 어텐션(Multi-Head Attention):** 입력 임베딩의 선형 변환을 통해 쿼리(Q), 키(K), 값(V) 3개의 벡터를 생성하고, 입력 시퀀스 단어 사이의 상호작용과 상관관계를


고려해 임베딩 벡터를 갱신함.

- 독립적인 셀프 어텐션을 여러 번 수행해 여러 개의 헤드를 생성하고 결과를 합침.
- **어텐션 스코어 계산식:**

$$score(v^q, v^k) = \text{softmax}\left(\frac{(v^q)^T \cdot v^k}{\sqrt{d}}\right)$$

- 벡터 차원(d)이 커질 때 스코어 값이 같이 커지는 문제를 완화하기 위해 제곱근 보정값을 나누어줌.
- **순방향 신경망(Feed-Forward Network):** 산출된 임베딩 벡터를 더욱 고도화하기 위해 사용되며, 선형 임베딩과 ReLU로 이루어진 인공 신경망이나 1차원 합성곱 계층이 사용됨. 입력 벡터에 가중치를 곱하고 편향을 더하며 활성화 함수를 적용하는 과정에서 단어의 의미를 파악하도록 가중치가 갱신됨.
- **덧셈 & 정규화(Add & Norm):** 어텐션 및 순방향 신경망 연산 이후 가중치 안정화를 위해 다시 수행되는 과정.

[트랜스포머 디코더]



- **트랜스포머 디코더:** 위치 인코딩이 적용된 타깃 데이터의 입력 임베딩을 받아 타깃 시퀀스 데이터를 순차적으로 생성함. 시퀀스의 순서 정보를 학습하며, 인코더의 출력 벡터 정보를 참조하여 입력과 출력 간의 관계를 고도화함.
- **마스크 멀티 헤드 어텐션(Masked Multi-Head Attention) 모듈:** 인코더의 일반 멀티 헤드 어텐션과 달리 인과성(Causality)을 반영하기 위해 대체된 모듈.

- 마스크를 적용하면 셀프 어텐션 연산 시 현재 위치 이전의 단어들만 참조할 수 있게 되어 미래 단어를 보지 못하도록 인과성이 보장됨.
- 디코더 입력 시퀀스에서 현재 위치 이후의 토큰을 마스크 처리하여 이전 토큰만을 참조함.
- **선형 임베딩 및 출력:** 최종적으로 생성된 디코더 출력 벡터는 선형 임베딩 계층으로 재표현되고 소프트맥스를 거쳐 최종 예측 확률로 산출되며, 자연어 모델 및 이미지 모델에 활용됨.

2. GPT

[GPT-1]

- **GPT-1:** 2018년 OpenAI에서 발표한 트랜스포머 구조 바탕의 **단방향 언어 모델**.
- **디코더 중심 구조:** 트랜스포머 디코더 블록을 12개 층으로 쌓아 구성함. 입력 문장의 특징 추출에 집중하는 인코더와 달리, 입력과 출력 문장 간의 관계를 이해하고 문장을 생성하는 데 초점을 맞추어 언어 모델링 작업에서 높은 성능을 보임.
- **동작 방식:** 텍스트를 생성할 때 현재 위치에서 이전 단어들에 대한 정보만을 참고해 다음 단어를 차례대로 예측함. 계산량이 줄어들기 때문에 학습 속도가 빠르고 모델 크기를 작게 유지할 수 있음.
학습 및 입력 제한: 대규모 텍스트 데이터셋으로 사전 학습(Pre-training)된 후 다운스트림 작업에 맞게 미세 조정(Fine-tuning)하여 사용하며, 입력 문장의 최대 길이는 512 토큰으로 제한됨.

[GPT-2]

- **GPT-2:** GPT-1보다 훨씬 더 많은 양의 데이터를 이용해 사전 학습된 후속 모델.
- **구조적 확장:** 12개의 층을 사용했던 GPT-1과 달리 **48개의 디코더 계층**을 사용하여 모델의 깊이와 복잡도를 크게 확장함. 이를 통해 이전보다 훨씬 더 정교하고 복잡한 언어 패턴을 학습할 수 있게 됨.
- **입력 처리 능력 확대:** 입력 문장을 최대 512 길이까지만 받아들일 수 있었던 한계를 극복하고, **최대 1,024 토큰의 길이**까지 입력을 처리할 수 있도록 문맥 수용량을 2배 늘림.

[GPT-3]

- **GPT-3:** 규모를 비약적으로 키워 기존 자연어 처리 분야의 기술적 한계를 극복한 거대 언어 모델.

- **규모 및 매개변수 극대화:** 몇몇 모델 매개변수 변화를 통해 GPT-2 대비 **약 116배 많은 매개변수**를 가진 모델로 진화함. 96개의 헤드를 가진 멀티 헤드 어텐션을 사용하며, 트랜스포머 디코더 층 역시 96개까지 쌓아 올림.
- **성능 및 일반화:** 질의 응답, 자연어 추론, 수학 문제 풀이, 일반 상식 등 새로운 도메인의 다운스트림 작업 프롬프트에 대해 별도의 미세조정 없이도 높은 일반화 능력을 보여줌.
- **한계점:** 거대한 모델 크기로 인해 추론 속도가 매우 느리고 컴퓨팅 비용이 많이 들어 일반 사용자나 소규모 기업에서 직접 활용하기 어려움. 또한 사전 학습 데이터에 의존하므로 데이터가 편향되거나 정확하지 않을 경우 부정확한 오류를 발생시킬 수 있음.

[GPT-3.5]

- **GPT-3.5:** GPT-3의 구조를 그대로 계승하면서 학습 방법론을 혁신하여 효율성과 자연스러움을 개선한 모델.
- **RLHF (Reinforcement Learning from Human Feedback) 도입:** 인간의 피드백을 사용하는 강화 학습 방법을 최초로 본격 도입함.
 - 1단계: 일부 데모 데이터를 사람이 직접 작성한 답변(SFT)으로 미세조정 학습함.
 - 2단계: 모델이 생성한 여러 답변을 사람이 좋은 순서대로 랭킹을 부여하고, 이 비교 데이터셋을 이용해 리워드 모델(RM)을 학습시킴.
 - 3단계: 평가된 리워드 점수를 보상으로 삼아 PPO 등의 알고리즘(Policy)으로 GPT-3 모델을 강화학습하여 최적화함.
- **효과 및 한계:** 대량의 매개변수 수를 효과적으로 최적화하고 실제 인간이 대화하듯 극도로 자연스러운 문장을 생성해 냄. 다만 학습 데이터양을 고려할 때 모든 프롬프트에 일일이 사람이 답변과 랭킹을 매기는 것은 현실적인 한계가 존재함.

[GPT-4]

- **GPT-4:** 이전 세대의 언어 모델들과 패러다임을 달리하는 차세대 트랜스포머 기반 대형 모델.
- **멀티모달(Multimodal) 모델로의 진화:** 기존 GPT 모델들이 오직 텍스트 데이터만을 입력받아 처리하고 예측할 수 있었던 반면, GPT-4는 텍스트 데이터뿐만 아니라 **이미지 데이터까지 함께 인식하고 처리**할 수 있도록 설계됨. 시각 정보와 언어 정보를 동시에 이해할 수 있게 되면서 활용 범위가 크게 확장됨.